

## 2. LK 光流

### 2.1 文献综述

1. 按此论文的分类, 光流法可分为additive和compositional; 以及forward和inverse.
2. 在compositional中, 为什么有时候需要做原始图像的 wrap? 该 wrap 有何物理意义?  
wrap定义了一个函数, 将输入图像上的像素点映射到目标图像上, 当用相机来追踪一个图像块在3D空间中移动时, wrap可以看做是一个仿射变换.  
在compositional中, 在原来wrap  $W(x; p)$  的基础上, 再进行一个微小的wrap  $W(x; \Delta p)$ 来缩小error, 因此需要对原始图像做wrap.
3. forward和 inverse差别  
forward使用正向的方式计算增量 $\Delta p$ , 而inverse则在计算增量时将Input和Template做了个交换, 计算的是增量的逆. 使用inverse的方法计算时, 由于Template图像是固定的, 因此Hessian矩阵是固定的, 可以预计算, 从而提高计算效率.

### 2.2 forward-addtive Gauss-Newton 光流的实现

1. 从最小二乘角度来看, 每个像素的误差怎么定义?  
从最小二乘角度看, 每个像素误差定义为, 根据追踪的结果移动后, 与目标光度的差:

$$e = I_1(x) - I_2(x + \mathbf{p})$$

这里 $\mathbf{p} = [\Delta x_i \ \Delta y_i]^T$ , 优化方程定义为:

$$\min_{\mathbf{p}} \sum_W \| I_1(\mathbf{x}) - I_2(\mathbf{x} + \mathbf{p}) \|^2$$

2. 相对于自变量的导数定义  
像素位置变化之后, 光度的变化率.

$$J = \frac{\partial e}{\partial \mathbf{p}} = -\Delta I_2|_{\mathbf{x}=\mathbf{x}+\mathbf{p}}$$

$\Delta \mathbf{p}$ 的计算方法:

$$\begin{aligned} J^T J \Delta \mathbf{p} &= -J^T e \\ \Rightarrow \Delta \mathbf{p} &= -(J^T J)^{-1} J^T e \end{aligned}$$

### 2.3 inverse

使用反向梯度来近似正向梯度:

$$J = \Delta I_1|_{\mathbf{x}}$$

### 2.4 multi-level

1. coarse-to-fine是指先在粗糙的图像上获取一个较大的偏移量, 然后再以此为初值在更精细的图像上获得较小的偏移量. 可以有效减少收敛到不好的局部最优的概率.
2. 光流法中使用图像金字塔, 可以在coarse的图像层上计算得到一个较好的初值, 从而收敛到更好的局部最优解, 使得光流对较大的相机运动任然具有可靠性. 而特征点法中图像金子塔的目的是提取不同尺度的特征.

### 2.5 讨论

1. 我们优化两个图像块的灰度之差真的合理吗? 哪些时候不够合理? 你有解决办法吗?  
优化两个图像块之间的光度误差不完全合理, 相机曝光不同, 或光照条件有变化时不合理, 对于有些物体有局部重复纹理的情况也不合理. 可以加入梯度一致性的cost, 以及周围patch光流值相似的cost.
2. 图像块大小是否有明显差异? 取16x16和8x8的图像块会让结果发生变化吗?  
当patch大小取为16x16时结果变差很多(能追踪到的点减少大概一半). 当patch大小取为 图像块大小2x2时追踪结果基本不正确. 选择合理的图像块大小对LK光流很重要.
3. 金字塔层数对结果有怎样的影响? 缩放倍率呢?  
根据构建金字塔的原因: 为了使得光流法对相机的大尺度运动有更好的鲁棒性, 在更粗糙的层上取得一个粗糙的初始值, 再步步细化. 因此, 实际应用中, 需要根据现实情况设置金字塔的层数(若相机运动较快则设置更多层, 反之则设置较少的层数). 缩放倍率的话, 一般取0.5. 假设光流的收敛像素范围不变的话, 那么取0.5正好以二进制的形式覆盖解空间.

代码运行结果

正向:

tracked by opencv

tracked single level

tracked multi level

247.4, 238.417  
871.696, 868.282  
18348.5, 18261.7  
487.189, 475.848  
311.757, 310.83  
176.492, 170.584  
447.797, 410.903  
224.336, 211.795  
403.838, 306.417  
306.2, 305.978  
316.151, 313.877  
299.009, 259.431  
4938.73, 4573.54  
174.599, 167.194  
309.902, 305.339  
181.225, 177.687  
331.339, 318.295  
450.458, 323.621  
204.102, 196.261  
824.92, 788.413  
434.251, 388.552  
309.3, 296.285  
165.693, 161.135  
195.868, 188.705

optical flow.cpp • code 20% (95)

Bot (1642,0) (Eshell Proj yas)

反向:

tracked by opencv

tracked single level

tracked multi level

8.417  
868.282  
18261.7  
475.848  
310.83  
170.584  
410.903  
211.795  
306.417  
5.978  
313.877  
259.431  
4573.54  
167.194  
305.339  
177.687  
318.295  
323.621  
196.261  
88.413  
388.552  
6.285  
161.135  
188.705

optical flow.cpp • code 20% (90,77) Gi

19,0) (Eshell Proj yas)

3 直接法

### 3.1 Single Level Direct

1. 该问题中的误差项是什么？  
误差项是重投影光度误差。

$$\begin{aligned} e &= I_{ref}(\pi(p)) - I_{cur}(\pi(T_{cur,ref} \mathbf{p})) \\ &= I_{ref} - I_{cur}(\frac{1}{Z} K \exp(\xi^\wedge) \mathbf{p}) \end{aligned}$$

2. 误差相对于自变量的雅可比维度是多少？如何求解？  
Jacobian维度为6维。

$$J = \frac{\partial e}{\partial \xi} = -\frac{\partial I_{cur}}{\partial \mathbf{u}} \frac{\partial \mathbf{u}}{\partial \mathbf{q}} \frac{\partial \mathbf{q}}{\partial \xi}$$

这里  $\mathbf{q} = \exp(\xi^\wedge) \mathbf{p}$ , 有:

$$\begin{aligned} \frac{\partial \mathbf{u}}{\partial \mathbf{q}} &= \begin{bmatrix} \frac{f_x}{Z} & 0 & -\frac{x f_x}{Z^2} \\ 0 & \frac{f_y}{Z} & -\frac{y f_y}{Z^2} \end{bmatrix} \\ \frac{\partial \mathbf{q}}{\partial \xi} &= [I \quad -\mathbf{q}^\wedge] \end{aligned}$$

使用Gaussian-Newton求解

$$\begin{aligned} H &= J^T J \\ b &= -J^T e \\ \Delta \xi &= H^{-1} b \\ \exp(\xi^\wedge) &\leftarrow \exp((\Delta \xi)^\wedge) \exp(\xi^\wedge) \end{aligned}$$

3. 窗口可以取多大？是否可以取单个点？  
对于窗口大小的取值, 和光流法一样, 需要取合适的大小. 不能取单个点, 与目标像素值相似的可以找到很多, 因此找到的解会很 inaccurate.

### 3.2 Multi-Level Direct

1. 在缩放图像时, 图像内参也需要跟着变化。那么, 例如图像缩小一倍,  $f_x, f_y, c_x, c_y$  应该如何变化？  
图像缩小一倍,  $f_x, f_y, c_x, c_y$  也缩小一倍。

### 3.3 延伸讨论

1. 直接法是否可以类似光流, 提出 inverse, compositional 的概念？它们有意义吗？  
将直接法与光流算法做类比, 所有选取的patch, 只优化一组参数  $\xi$ .  
wrap函数  $W(\mathbf{x}; \xi)$  可以不规范地表示为(等式右边去除计算结果的最后一维):

$$W(\mathbf{x}; \xi) = \frac{1}{Z'} K \exp(\xi^\wedge) Z K^{-1} \begin{bmatrix} u \\ v \\ 1 \end{bmatrix}$$

这里,  $Z'$  是重投影到img2上的深度,  $Z$  是原来在img1中的深度,  $\mathbf{x} = [u \ v]^T$   
误差项表示为:

$$I_1(\mathbf{x}) - I_2(W(\mathbf{x}; \xi))$$

根据我们之前使用的李代数扰动模型, 之前的实现方式就是compositional正向的方法:

$$\begin{aligned} \exp(\xi^\wedge) &\leftarrow \exp((\Delta \xi)^\wedge) \exp(\xi^\wedge) \\ e &= I_1(\mathbf{x}) - I_2(W(W(\mathbf{x}; \Delta \xi); \xi)) \end{aligned}$$

相应地若是提出inverse的方法则误差和更新方式为:

$$\begin{aligned} e &= I_1(W(\mathbf{x}; \Delta \xi)) - I_2(W(\mathbf{x}; \xi)) \\ \exp(\xi^\wedge) &\leftarrow (\exp((\Delta \xi)^\wedge))^{-1} \exp(\xi^\wedge) \end{aligned}$$

img1, img2,  $\xi_{21}$ , 我们计算一个 $\Delta\xi$ 对img1中的patch进行位置调整, 使得img1的patch更接近与img2的patch, 若是如此, 则需要两张图像都带有深度. 再都有深度的情况下, 可以直接用ICP, 没有必要使用直接法, 因此意义不大.

2. 请思考上面算法哪些地方可以缓存或加速?

在计算Jacobian和error时可以并行计算.

3. 在上述过程中, 我们实际假设了哪两个 patch 不变?

我们假设img1中的点, 重投影到img2上之后, 其周围的patch像素值不变.

4. 为何可以随机取点? 而不用取角点或线上的点? 那些不是角点的地方, 投影算对了吗?

可以直接取点的原因是, 与特征点法以及光流法不同, 直接法优化的变量是一个全局的Transform, 因此, 不需要每个点都贡献很多约束, 只要全局的约束足够就能够求解. 不是角点的地方, 投影误差相对比是角点的地方大, 但大部分也是对的.

5. 直接法相对与特征点法的优点

直接法优点:

- 可以省去计算特征点、描述算子的时间.
- 只需要有像素梯度即可, 无需特征点, 可以应用在特征缺失的场景中.
- 可以构建半稠密乃至稠密的地图.

直接法缺点:

- 非凸性, 直接法完全依靠梯度搜索, 降低目标函数来计算相机位姿. 而图像是强烈非凸函数, 这使得优化算法容易进入极小. 只在运动很小时直接法才能成功.
- 单个像素没有区分度, 因此需要以图像块做计算. 当每个像素对改变相机运动的"意见"不一致时, 只能少数服从多数, 以数量代替质量.
- 灰度不变是很强的假设. 若相机自曝光, 当相机曝光参数改变时, 或者当光照变化时该假设被破坏.

## 程序运行结果

为了标记不同的patch, 对颜色做了一些修改. 这里, 程序还有两个问题(bug):

1. 每次运行的结果都有不同.
2. 另外当显示图像时, 最终结果可能会错.

望指点一二.



## 使用光流计算视差

程序执行结果(其中红点是光流计算的深度点):



